

# Vorbericht

Projekt Big Data Management — Sommersemester 2026  
TU Clausthal — Institut für Informatik

**Name:** Ramane Gbatkom Mouliom Abdel  
**Matrikelnummer:** 603155  
**Studiengang:** Informatik B.Sc.  
**Betreuer:** M.Sc. Denis Kruschinski  
**Datum:** 28. Juni 2026

---

## 1. Thema

Data Quality & Anomaly Detection auf Luxury Cosmetics Datensatz

## 2. Datensatz

*Luxury Cosmetics Fraud Analysis 2025* (Kaggle) mit 2.134 Transaktionsinformationen und 16 Merkmalen wie zum Beispiel `Purchase_Amount`, `Product_Category`, `Payment_Method`, `Device_Type`, `Customer_Loyalty_Tier`, sowie einem binären Label `Fraud_Flag` zur späteren Validierung der erkannten Anomalien.

Link zu dem Datensatz: [Luxury Cosmetics Fraud Analysis 2025](#).

## 3. Fragestellung

Wie können wir typische Qualitätsprobleme bei Luxury Cosmetics Datensätze durch Datenprofiling erkennen und Betrugsmuster mit dem Isolation Forest sichtbar machen?

## 4. Mein Vorgehen

Ich werde die folgende drei Schritten verfolgen:

- Zuerst werde ich ein systematisches Datenprofiling durchführen, um Datentypen, Duplikate, fehlende Werte und Ausreißer zu analysieren.
- Dann basierend auf die Datenprofilingsanalyse werde ich vier automatisierte Qualitätsprüfung (Quality-Checks) implementieren.
- Am Ende werde ich der Isolation Forest aus scikit-learn für die unüberwachte Anomalieerkennung einsetzen. Die ermittelten Muster werden mit den echten Betrugs-Labels verglichen, bewertet und im Bericht in Form von konkreten Handlungsempfehlungen dokumentiert. Das Ziel dahinter ist ein verständliches Qualitätskonzept, das als stabiles Fundament für zukünftige Produktionspipelines dient.

## 5. Verwendete Tools

- Jupyter Notebooks, Python
- NumPy
- scikit-learn
- Matplotlib

## 6. Zeitplan

| Aufgaben                                                | Deadline   |
|---------------------------------------------------------|------------|
| Vorbericht eingereicht                                  | 15.06.2026 |
| Datensatz geladen + Datenprofiling abgeschlossen        | 25.06.2026 |
| 5 Quality-Checks implementiert + automatisiert          | 02.07.2026 |
| Isolation Forest trainiert + Anomalien interpretiert    | 09.07.2026 |
| Vergleich Anomalien vs. Fraud-Labels + Visualisierungen | 11.07.2026 |
| Präsentationsfolien fertig + an Betreuer geschickt      | 12.07.2026 |
| Präsentation                                            | 15.07.2026 |
| Erste Version Projektbericht                            | 28.07.2026 |
| Überarbeitung + Korrekturen                             | 08.08.2026 |
| Abgabe der Ausarbeitung                                 | 14.08.2026 |

## 7. Erwartete Ergebnisse

- Jupyter Notebook mit Profiling, Quality-Checks und Anomalie-Ergebnissen
- Projektbericht mit wichtigsten Datenproblemen und Handlungsempfehlungen
- Präsentationsfolien